

Trabajo Práctico Integrador: Pipeline ETL & Inteligencia de Mercado (Food Delivery)

Módulo: Python para Análisis de Datos (ETL)

Instructor: Christian Condori

Modalidad: Individual o en pareja (máximo 2 personas)

Puntaje máximo: 20 puntos

Contexto de Negocio

Usted ha sido contratado como Data Engineer y Analista BI por el CEO de una nueva startup de *Food Delivery* que busca expandirse en Estados Unidos. Antes de lanzar la aplicación y decidir en qué ciudades invertir, el directorio necesita entender cómo operan sus competidores actuales, qué categorías dominan el mercado y cómo se comportan los precios según la región.

El equipo de *Web Scraping* le ha entregado dos archivos crudos. Su misión es construir un pipeline ETL completo: extraer los datos, realizar una limpieza profunda (separar direcciones, traducir rangos de precios), optimizar el tamaño, cargarlos en un motor SQL local (SQLite) y, finalmente, responder a las preguntas críticas del CEO utilizando consultas SQL y gráficos profesionales.

Datasets (Carpeta **data/**)

Archivo	Descripción	Filas Aprox.
restaurants.csv	Catálogo maestro de restaurantes. Contiene dirección completa concatenada, puntajes y rango de precios en símbolos (\$).	63,000
restaurant-menu.csv	Detalle de cada ítem vendido. Contiene el nombre del plato y su precio en texto.	5,000,000

Arquitectura Objetivo

1. **EXTRACT:** Lectura de CSVs usando Pandas.
2. **TRANSFORM:** Separación de columnas (Split), Mapeo de diccionarios, limpieza de texto, casteo de tipos numéricos y reducción estratégica del dataset.
3. **LOAD:** Creación de base de datos local `delivery_insights.db` usando `SQLAlchemy` y carga de la tabla final.
4. **BUSINESS INTELLIGENCE:** Lectura desde SQLite (`pd.read_sql`) y generación de reportes visuales con `Seaborn/Matplotlib` para el Directorio.

Consignas del Proyecto

Parte 1 - Extracción y Diagnóstico (Extract)

1. Cargue ambos archivos CSV en DataFrames de Pandas (`df_restaurantes` y `df_menus`).
2. Realice un análisis exploratorio (Data Profiling): Imprima las dimensiones (`.shape`), los tipos de datos (`.dtypes`) y la cantidad de valores nulos por columna de ambos DataFrames.

Parte 2 - Ingeniería de Características y Limpieza (Transform)

En `df_restaurantes`:

1. **Mapeo de Precios:** La columna `rango_de_precios` contiene símbolos (\$, \$\$, etc.). Utilice un diccionario y la función `.map()` o `.replace()` para transformarlos a texto legible:
 - \$ -> "Económico"
 - \$\$ -> "Moderadamente caro"
 - \$\$\$ -> "Caro"
 - \$\$\$\$ -> "Muy caro"
2. **Desanidado de Ubicaciones (Split):** La columna `dirección_completa` contiene la calle, ciudad, estado y código postal separados por comas. Utilice el método `.str.split(',', expand=True)` para crear **tres nuevas columnas**: `calle`, `ciudad` y `estado_zip`. Asegúrese de aplicar `.str.strip()` a la nueva columna `ciudad` para quitar espacios ocultos.
3. **Filtro de Calidad:** Elimine los restaurantes que no tengan puntaje (`score` nulo) o cuyo puntaje sea 0. Estandarice la columna `category` a minúsculas.

En `df_menus`:

1. La columna `price` viene como texto (ej. "15,99 USD"). Cree una función lambda o use `.str.replace()` para eliminar el texto " USD", reemplazar la coma por un punto, y castear el resultado a formato decimal (`float`).
2. Elimine los ítems del menú con precio igual a 0.0 o nulos.

Optimización y Cruce (Control de Memoria RAM):

1. Para no colapsar la memoria del servidor, el CEO solo quiere analizar los restaurantes consolidados. Filtre `df_restaurantes` para quedarse **únicamente con aquellos que tengan más de 100 calificaciones** (`ratings`).
2. Realice un `INNER JOIN` (`pd.merge`) entre su `df_restaurantes` filtrado y `df_menus` utilizando el ID del restaurante. Guarde este cruce en un DataFrame llamado `df_master`.

Parte 3 - Carga a Base de Datos (Load)

1. Importe la librería `sqlalchemy` y genere un motor (`create_engine`) para una base de datos SQLite local llamada `delivery_insights.db`.
2. Utilice `df_master.to_sql()` para cargar su tabla final a la base de datos con el nombre `master_food_data`. Use `if_exists="replace"` y `index=False`.

Parte 4 - Business Intelligence: Reporte al CEO (SQL + Visualización)

Conéctese a su base de datos SQLite mediante `pd.read_sql(text(query), conn)`. **Por cada pregunta, presente el Query ejecutado, el DataFrame resultante y un gráfico explicativo de alto nivel.**

1. **Penetración Geográfica:** ¿Cuáles son las **5 ciudades** (`ciudad`) con la mayor cantidad de restaurantes consolidados (los que quedaron en nuestra base)?
Gráfico sugerido: Gráfico de barras horizontal ordenado de mayor a menor.
2. **Análisis de Oportunidad de Precio:** El CEO cree que todos los restaurantes en el mercado son caros. Usando los datos, muestre la distribución de la columna `rango_de_precios` a nivel general (¿Cuántos hay en "Económico", "Caro", etc.?).
Gráfico sugerido: Gráfico de torta (Pie chart) o Donut chart.
3. **Estrategia de Menú por Ciudad:** Para las 3 ciudades más populares obtenidas en la pregunta 1, calcule el **precio promedio de los platos en el menú**. ¿En qué ciudad es más caro comer en promedio? *Gráfico sugerido: Gráfico de barras comparativo.*
4. **La Pregunta del Millón (Correlación Precio-Calidad):** ¿Un restaurante más caro garantiza una mejor experiencia para el usuario? Escriba un query que calcule el puntaje (`score`) promedio agrupado por `rango_de_precios`. Utilice un gráfico de líneas o de barras para demostrar visualmente al CEO si la calidad sube a medida que aumenta la categoría de precio.

Formato de Entrega

La entrega se realizará mediante un **repositorio público en GitHub**. El alumno (o equipo) enviará al instructor la URL del repositorio.

Instrucciones para el repositorio:

1. Nombre sugerido para el repositorio: **[su_apellido]-proyecto-etl-delivery**.
2. El repositorio debe ser público.
3. Debe contener el cuaderno de Google Colab descargado en formato **.ipynb**.
4. El cuaderno debe estar ordenado utilizando Bloques de Texto (Markdown) con emojis para separar claramente las Fases (EXTRACT, TRANSFORM, LOAD, BI).
5. En la Parte 4, agregue una pequeña celda de texto después de cada gráfico brindando una **breve conclusión de 1 línea** al CEO.

Rúbrica de Evaluación

Bloque	Tema	Puntos
A	Extracción: Lectura correcta y reporte de exploración inicial.	2
B	Limpieza Avanzada: Split correcto de la dirección, mapeo de precios y casteo numérico.	6
C	Cruce y Load: Aplicación de filtros de optimización, Merge sin errores y creación de BD SQLite.	4
D	Business Intelligence (SQL): Queries lógicas, eficientes y correctamente estructuradas.	3
E	Data Storytelling: Gráficos profesionales (títulos, etiquetas legibles) y conclusiones para el CEO.	3
F	Entregable en GitHub: Repositorio público, código comentado y formato Markdown correcto.	2
Total		20